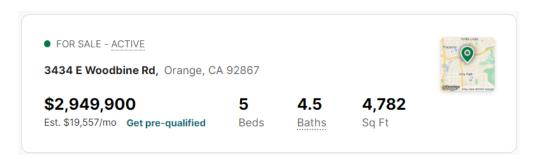
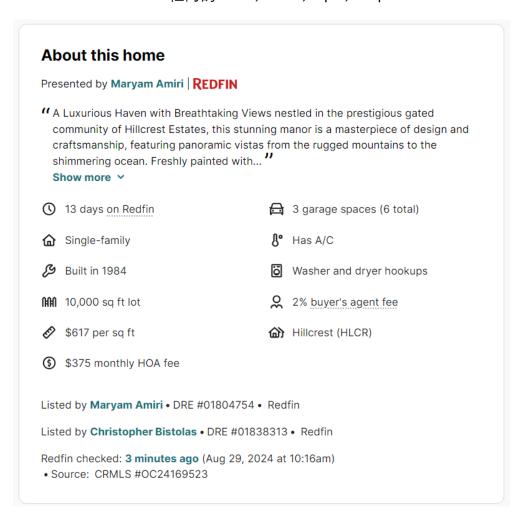
## Redfin 爬虫存在的主要问题及解释

"Redfin 资料需求.xlsx"表格中的数据可以分为两类,分别是**静态内容**和<u>动态内容</u>。静态内容是网页中直接包含在 HTML 文件中的内容,<u>无需额外的用户交互或后续的脚本执行即可显示</u>, 页面加载后这些内容是固定的,可以直接解析。表格中以下内容为静态内容:

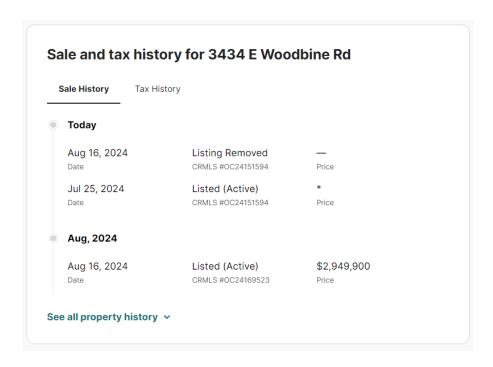


For Sale 框内的 Beds, Baths, Sq Ft, Est price.

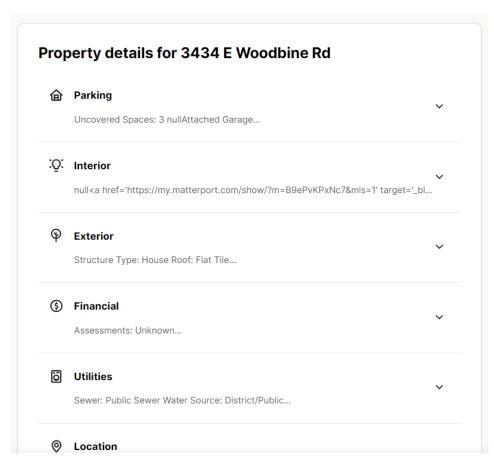


## About this home 的内容

反之,动态内容是指需要通过 JavaScript 执行、用户交互(如点击或滚动),或异步请求(如 AJAX)从服务器获取并显示的内容。页面初次加载时,这些内容通常不直接包含在 HTML 中,而 是由客户端(浏览器)在页面加载后生成或请求。表格中以下内容为动态内容:



Sale and tax history

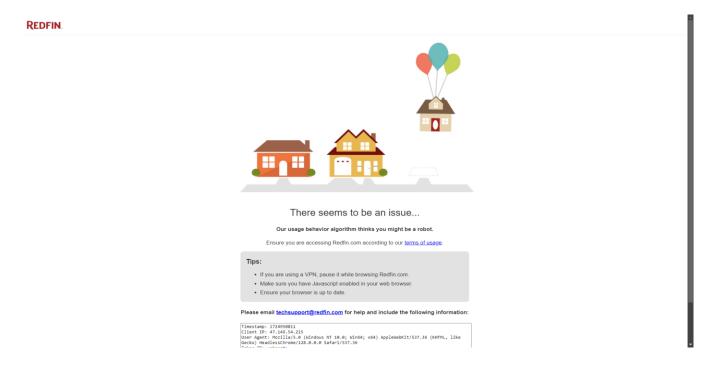


Property details

如果用户不进行交互,如不点击"tax history"或不展开 Exterior 的模块,那么里面的内容就不会显示,这就要求爬虫具备网页交互的能力。

Redfin 的爬虫协议支持获取以上的**静态内容**,但是会严格检测用户端浏览器的交互行为,如果用户存在快速交互和频繁开关浏览器等可疑行为,就会违反协议并被禁止访问所有网页的内容。

以下是我的爬虫遭到拦截返回的截图,实测间隔在 1-5 分钟的访问和交互均会被认定为恶意行为。



因此,如果要实现多个地址的数据爬取并规避上述检测行为,爬虫有以下要求:

- 1. 仅爬取静态页面的数据
- 2. 设置爬取间隔,也就是等待 5 分钟以上再进行下一个地址数据的爬取,或者在同一个页面下,每隔 5 分钟以上进行一次交互(如展开下拉目录)。